📈 나만의 데이터로 미래를 예측하다

Orange3 선형 회귀 실습 보고서

— 두 변수의 관계를 스스로 찾아 예측 모델 만들기 —

학년 반 번호		이름	박민준	제출일	2026 . 09 . 23

🎯 미션 우리 주변에는 '하나가 늘면 다른 하나도 규칙적으로 변하는' 관계가 많습니다. 공부 시간과 성적, 기온과 아이스크림 판매량, 팔로워 수와 좋아요 수처럼요. 이번 활동에서는 내가 직접 고른 두 변수(x, y)의 데이터를 모아 산점도를 그리고, 노코딩 머신러닝(ML) 도구 Orange3로 선형 회귀 예측 모델을 만든 뒤, 그 예측이 믿을 만한지 스스로 검증합니다.

🏆 이 보고서는 수행평가① **"Orange3 선형회귀 탐구"** 입니다. 만점 **30**점 · 기본점수**9**점 세 영역 각 10점(영역1·영역2·영역3)으로 채점합니다. ※ **AI(생성형 AI 포함)** 활용은 원칙적으로 금지합니다.

영역 1 데이터 이해 및 회귀식 추정 [10점]

📋 평가요소 (배점 근거)

① 선형 관계가 나타나는 탐구 주제·데이터를 목적에 맞게 선정하고, 독립·종속 변수의 관계를 올바르게 파악하였는가? → 1-1

② 산점도를 근거로 회귀식(y=ax+b)을 합리적으로 추정하였는가? → 1-2-1·1-2-2

③ 기울기·절편의 의미를 데이터 맥락에서 설명하였는가? → 1-3

1-1 탐구 주제와 데이터 정하기 (내 탐구 설계)

💡 어떤 관계를 예측해 볼까? 아래는 아이디어일 뿐입니다. 관심 분야에서 자유롭게 골라도 좋고, 직접 새로운 주제를 만들어도 됩니다.

분야	예시 주제 (독립변수 **x** → 종속변수 **y**)
일상·소비	기온 → 아이스크림(또는 음료) 판매량 · 광고비 → 매출액
학습·생활	공부 시간 → 시험 점수 · 수면 시간 → 집중도 자기평가 점수
사회·미디어	팔로워 수 → 게시물 좋아요 수 · 영상 길이 → 조회수
과학·환경	음료 온도 → 얼음 녹는 시간 · 용수철에 매단 무게 → 늘어난 길이
스포츠·건강	키 → 몸무게 · 연습 시간 → 기록(초·점수)

✅ 좋은 데이터의 조건

· 두 변수 모두 숫자(연속형)이고, 하나가 변하면 다른 하나도 대체로 함께 변하는 관계일 것

· 데이터 개수는 최소 8개 이상 (많을수록 회귀선이 안정적)

· 직접 측정·설문하거나 공공데이터(KOSIS·기상자료개방포털 등)에서 수집 — 출처를 반드시 기록

탐구 주제	KBO 선수의 승리기여도와 연봉사이 선형 관계
독립변수 **x**	WAR (대체 수준 대비 승리 기여도)
종속변수 **y**	선수 연봉 (만원)
데이터 출처	KBO 공식 홈페이지, STATIZ
예상 관계	x가 커지면 y는 증가할 것이다. WAR이 높은 선수일수록 팀 승리 기여도가 높은 것인데 이런 평가가 선수의 연봉에 반영될 것이라고 생각한다.

1-2-1 내 훈련 데이터 입력하기 (train.csv)

💡 수집한 훈련 데이터를 구글 시트나 엑셀에 입력하고 train.csv로 저장하세요. 첫 행은 변수 이름(x, y)으로 합니다.

독립변수 **x (WAR)**	종속변수 **y (** 연봉 **)**
7.14	3,300
4.18	41,000
4.96	120,000
2.16	70,000
3.61	17,500
0.50	30,000
8.92	112,000
5.14	72,800
4.11	35,000
2.63	9,400
-0.02	33,000
1.08	20,000

WAR	선수 연봉(만원)
7.14	3,300
4.18	41,000
4.96	120,000
2.16	70,000
3.61	17,500
0.5	30,000
8.92	112,000
5.14	72,800
4.11	35,000
2.63	9,400
-0.02	33,000
1.08	20,000

1-2-2 규칙을 찾아 회귀식 손으로 추정하기

🧠 x가 일정하게 커질 때 y는 얼마씩 변하나요? 표에서 규칙을 찾아 직선의 식 y = a x + b 로 손으로 추정해 보세요.

x가 한 단위 커질 때 y는 약 7,000만 원만큼 증가한다. 기울기 a ≈ 7,000, 절편 b ≈ 25,000 . 따라서 y =7000x + 25,000 으로 예상한다.

1-3 기울기와 절편의 의미 해석

기울기 a는 WAR이 1 증가할 때 선수의 예상 연봉이 약 7,000만원 증가한다는 의미이다. 절편b는 WAR이 0일때 예상되는 연봉으로 약 25,000만 원을 의미한다.

영역 2 Orange3 예측 모델 구성 [10점]

📋 평가요소 (배점 근거)

① train-test 데이터를 적절히 구성하였는가? → 1-2(train)·2-1(test)

② 워크플로우(File→Scatter Plot→Linear Regression→Predictions)를 올바르게 연결하였는가? → 2-2

③ 모델의 예측값을 산출하고 실제값(손 계산)과 비교하였는가? → 2-3

2-1 내 테스트 데이터 만들기 (test.csv)

💡 훈련 데이터 범위 안에서 x값 5개 정도를 골라 테스트 데이터(test.csv)를 만드세요. y열은 비워 둡니다.

독립변수 x	종속변수 y (비움)
5.78	?
4.02	?
3.71	?

2.53	?
1.45	?

2-2 Orange3 워크플로우 구성하기

📌 워크플로우 순서

① File 위젯 → train.csv 불러오기 (이름: train data)

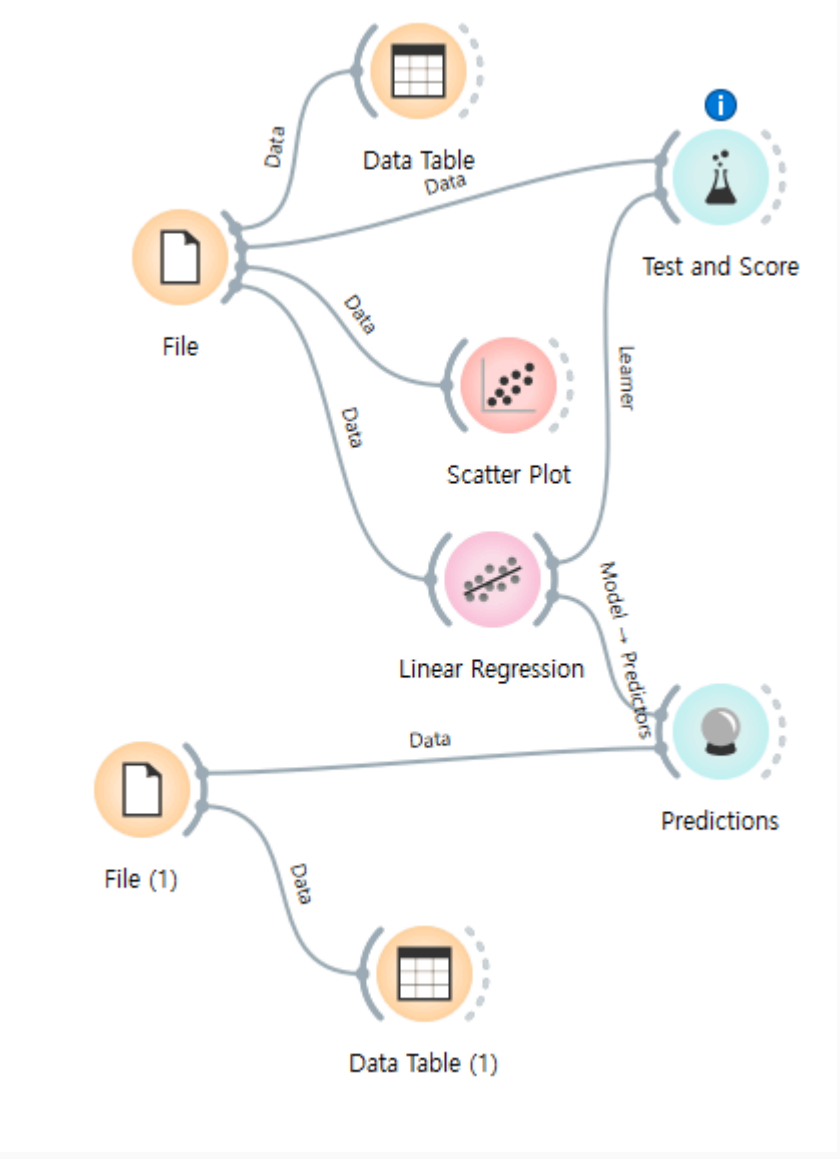
② Data Table 위젯 연결 → 데이터 확인

③ Scatter Plot 위젯 연결 → 산점도 확인 (x축: 독립변수, y축: 종속변수)

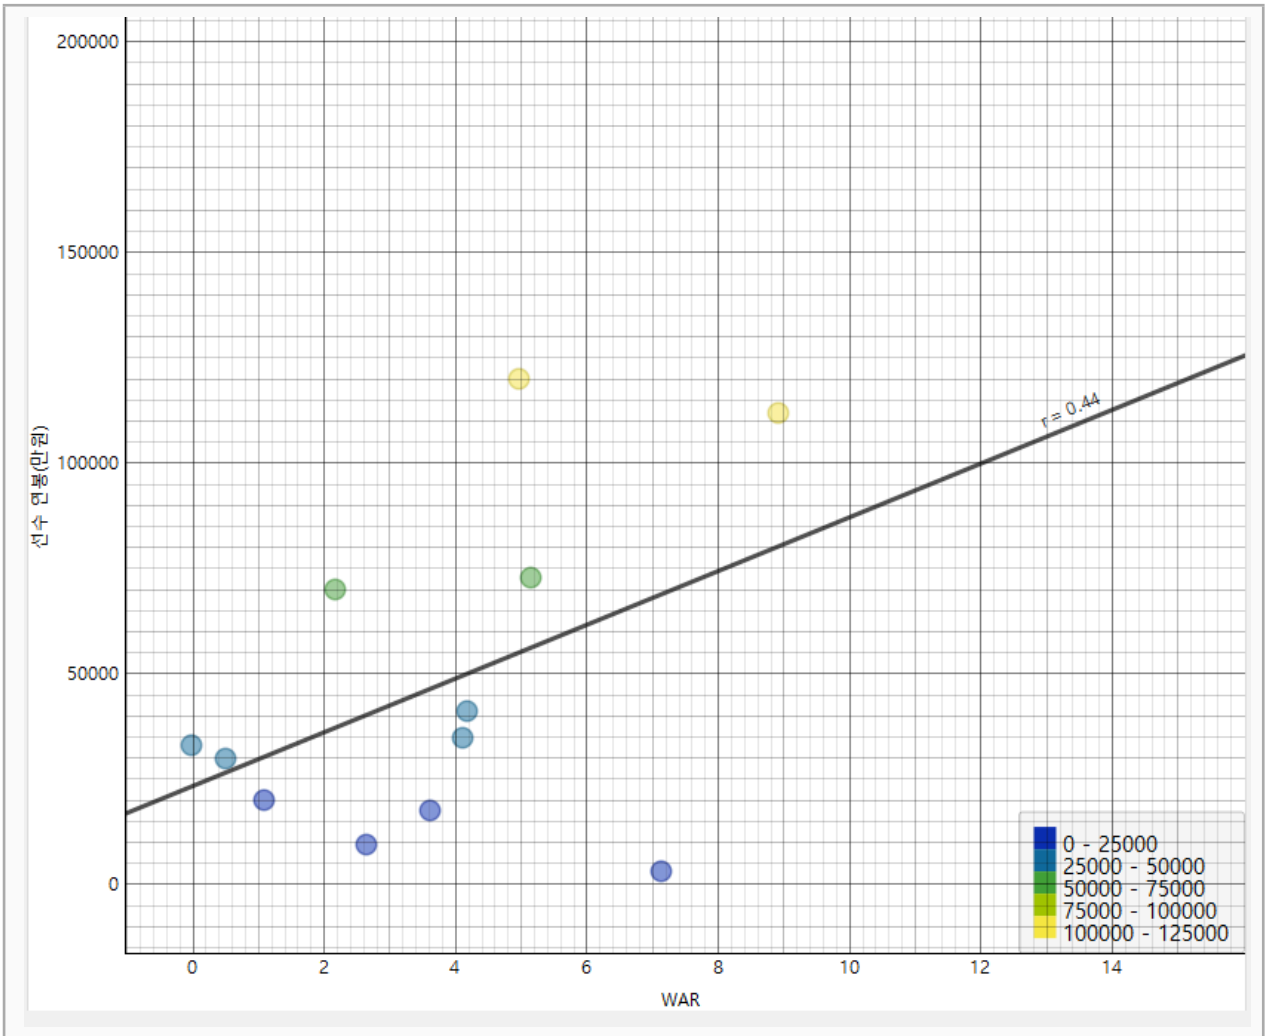
④ Linear Regression 위젯 연결 → 모델 학습

⑤ 새 File 위젯 → test.csv 불러오기 (이름: test data)

⑥ Predictions 위젯 → 모델 + 테스트 데이터 연결

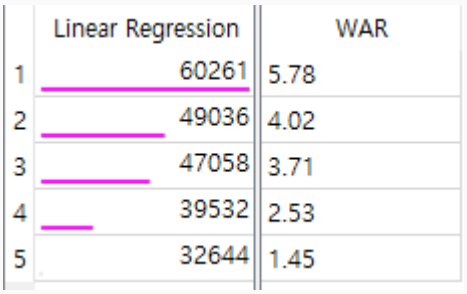


산점도 확인 및 관찰



데이터 점들은 전체적으로 왼쪽 아래에서 오른쪽 위 방향으로 분포하고 WAR이 증가할수록 연봉도 증가하는 양의 관계가 나타난다. 다만 일부 데이터는 회귀선에서 벗어나 있고 상관계수도 0.44로 중간 정도의 상관을 보여준다.

2-3 예측 결과 비교 (내 손 계산 vs Orange3)



	Linear Regression	WAR
1	60261	5.78
2	49036	4.02
3	47058	3.71
4	39532	2.53
5	32644	1.45

x 값	내가 계산한 예측값 (y=ax+b)	Orange3 예측값
5.78	7,000*5.78 +25,000 = 65,460	60,261
4.02	7,000*4.02 +25,000 = 53,140	49,036
3.71	7,000*3.71 +25,000 = 50,970	47,058
2.53	7,000*2.53 +25,000 =42,710	39,532
1.45	7,000*1.45 +25,000 =35,150	32,644

영역 3 결과 검증 및 해석 [10점]

📋 평가요소 (배점 근거)

① 회귀선과 평가지표(R²·MAE·RMSE)로 예측 결과의 타당성을 검증하였는가? → 3-1

② 정비례·반비례 등 관계의 방향과 의미를 데이터 맥락에서 해석하였는가? → 3-2

③ 모델의 한계(외삽의 위험)를 탐구하고, 활동을 통해 배운 점을 성찰하였는가? → 3-3·3-4

3-1 회귀선으로 타당성 검증

내 손 계산값과 Orange3의 예측값이 전체적으로 비슷한 값을 나타내지만 약간의 차이가 있다. 모든 예측값은 양의 상관관계를 보이며 산점도의 회귀선 주변에 위치하는 경향이 있다. 이 모델이 데이터의 규칙을 잘 학습했다고 판단할 수 있다.

3-1-2 모델 평가지표로 신뢰도 검증 (Test and Score · 심화)

🌟 **(심화) Test and Score**로 모델의 신뢰도를 '숫자'로 검증하기

① **[Evaluate] → [Test and Score]** 위젯을 추가한다.

② **train data(File)**를 **Data**로, **Linear Regression**을 **Learner**로 각각 연결한다.

③ 평가 방법은 **Cross validation**(교차검증, 기본값)으로 두고 아래 세 지표를 읽어 기록한다.

(MSE·MAPE도 함께 나오지만 **R²·MAE·RMSE**에 집중. **RMSE = MSE**의 제곱근)

평가지표	내가 기록한 값	이 값이 뜻하는 것 (내 해석)
R^2 (결정계수)	-0.41	R2가 1에서 멀고 심지어 음수로 나타나므로 이 모델의 예측성능이 매우 낮다.
MAE (평균오차)	35507.87	실제 연봉과 예측 연봉의 차이가 평균적으로 약 3억 5,508만 원 정도 발생한다.
RMSE	43501.85	예측 오차가 평균적으로 약 4억 3,502만원 수준이고 MAE보다 크기 때문에 일부 데이터에서 큰 오차가 발생했다.

R2이 -0.4로 나타나 1에서 크게 멀어 예측 성능이 높다고 보기 어렵고 연봉은 WAR로 결정되는 것이 아니라 경력, 포지션, FA 여부, 계약 조건등 다른 요인의 영향을 크게 받는다 . 또한 MAE와 RMSE가 크게 나타나 실제 연봉과 예측값 사이에 상당히 큰 차이가 있는 것을 확인할 수 있었다. 특히 RMSE가 MAE보다 큰 것은 일부 데이터에서 큰 오차가 발생했기 때문이다. 교차검증에서는 학습에 사용하지 않은 데이터를 예측하므로 전체 데이터에 맞춘 경우보다 성능이 낮게 나타날 수 있다. 따라서 이 모델은 WAR과 연봉의 전체적인 관계성을 확인하는 데는 활용할 수 있지만 연봉을 정확하게 예측하는 데에는 한계가 있다

3-2 결과 해석 — 숫자 뒤의 의미

WAR과 연봉은 정비례가 아닌 양의 관계가 나타나고 WAR이 증가할수록 예상 연봉도 증가하는 경향을 보인다. 기울기 약 7,000은 WAR이 1 증가할 때 예상 연봉이 약 7,000만 원 증가한다는 의미이다. 실제 이번 시즌 한화 선수들의 WAR을 테스트 데이터로 입력했는데 허인서는 이 모델에서 약 4억 9,036만 원으로 예측되었지만 실제 연봉은 3,600만 원이고 노시환은 약 4억 7,058만 원으로 예측되었지만 실제 연봉은 10억 원이다. 이처럼 실제 연봉과 예측값 사이에 큰 차이가 나타나는 것을 통해 선수 연봉은 WAR뿐 아니라 경력, FA 여부, 계약 조건 등 여러 요인의 영향을 받는다는 것을 알 수 있었다. 따라서 이 모델은 WAR과 연봉의 관계성을 파악하는 참고 자료 정도로는 활용할 수 있지만 연봉을 정확하게 예측하는 데에는 큰 한계가 있다.

3-3-1 한계 탐구 — 극단값 실험 (외삽의 위험)

🤔 학습 데이터 범위를 크게 벗어난 x값을 회귀식에 넣으면 예측이 현실적으로 말이 될까요?

외삽(Extrapolation)의 위험을 확인해 봅시다.

극단적인 **x** 값	모델 예측값 **y**	현실적으로 가능한가**?**
-5	-8494	불가능
30	214,736	불가능

극단적인 x값 WAR이 -5일 때 연봉이 -8,494만 원으로 예측되어 선수가 연봉을 내야하는 것 같은 현실적으로 존재할 수 없는 결과가 나타났다. 또한 WAR이 30일 때 연봉이 214,736만 원으로 예측되었는데 이 값은 학습 데이터의 WAR 범위인 약 -0.02~8.92를 크게 벗어난 값이므로 현실적인 예측이라고 보기 어렵다. 따라서 선형 회귀는 학습 데이터가 충분히 존재하는 범위 안에서 예측할 때 신뢰할 수 있고 범위를 크게 벗어난 값은 주의를 가져야 한다.

3-3-2 활동 성찰

📝 활동을 돌아보며 이번 활동에서 '어떤 문제 → 어떻게 해결 → 무엇을 배웠는지'와, 선형 회귀로 예측할 때 주의할 점(3-3의 외삽 실험과 연결)을 함께 정리하세요. 성실히 쓰면 세특(세부능력 및 특기사항) 작성의 좋은 소재가 됩니다.

📝 활동 성찰 — '어떤 문제 → 어떻게 해결 → 무엇을 배웠는지' 흐름으로 쓰면 세특 작성의 좋은 소재가 됩니다.

이번 활동에서 가장 어려웠던 문제는 훈련 데이터를 고르는 과정이었다. 처음에는 WAR과 연봉이 규칙적으로 변하는 데이터를 찾아서 넣어야 하는 건지 고민했는데 그렇게 하면 회귀 모델의 R2이 인위적으로 높게 나올 것 같다는 생각이 들어 실제 선수들의 WAR 값을 임의로 뽑아 사용했다. 이후 모델을 검증했을 때 R2이 음수 값이 나와서 당황했다. 결정계수가 음수로 나올 수도 있는 것인지 궁금해 직접 검색해본 결과 R2이 음수라는 것은 내가 만든 회귀 모델이 단순히 평균값으로 예측하는 것보다도 성능이 나쁘다는 의미라는 것을 알게 되었다. 이 과정을 통해 선형 회귀가 하나의 변수로 결과를 설명하려는 단순화된 모델이라는 한계를 느낄 수 있었다. 변수 하나만으로는 제대로 설명할 수 없었고 실제로 예측값과 실제의 차이가 컸다. 이는 다양한 요인에 영향을 받기 때문임을 알 수 있었다. 이번 활동을 통해 선형 회귀 모델을 해석할 때는 회귀선의 방향뿐 아니라 R2, MAE, RMSE 같은 지표를 같이 보고 모델의 한계를 파악하는 것이 필요하다는 것을 배웠다

📚 핵심 개념 요약

· 지도학습 : 정답(레이블)이 있는 데이터로 모델을 훈련시키는 방법

· 회귀(Regression) : 연속적인 숫자 값을 예측하는 문제 유형

· 선형 회귀 : y = ax + b 직선으로 데이터의 패턴을 표현하는 알고리즘

· 기울기 a의 부호 : a>0이면 양의 관계(정비례), a<0이면 음의 관계(반비례)

· 외삽(Extrapolation)의 위험 : 학습 데이터 범위를 벗어난 예측은 신뢰하기 어려움

· 결정계수(R^2) : 모델이 데이터를 설명하는 비율(0~1). 단순 선형회귀에서는 상관계수의 제곱($R^2=r^2$)

· MAE / RMSE : 예측 오차의 크기(작을수록 좋음). RMSE는 큰 오차(이상치)에 더 민감

· 교차검증(Cross validation) : 데이터를 나눠, 학습에 쓰지 않은 부분으로 평가 → 모델의 '진짜 실력(일반화 성능)' 측정

· 훈련 vs 검증 성능 : 본 데이터엔 잘 맞고(훈련), 처음 보는 데이터엔 조금 못 맞음(검증). Test and Score 값이 검증 성능

🔎 수행평가 채점표 (교사 기입용)

채점 기준: 아래 참고

※ 저작권·데이터 윤리 미준수, 평가 윤리 미준수, AI 활용 금지 원칙 위반 등 부적절 상황 발생 시 해당 영역 0점 처리.

평가영역	배점	채점 기준 (해당 점수에 ○)	획득 점수
[영역1] 데이터 이해 및 회귀식 추정	10점	10 · 8 · 6 · 4	
[영역2] Orange3 예측 모델 구성	10점	10 · 8 · 6 · 4	
[영역3] 결과 검증 및 해석	10점	10 · 7 · 4 · 1	
합계	**30**점	기본점수 9점	**/ 30**